

1. 모델 선정 과정

1.1 1 차 모델링: 단일 16-class LightGBM 기준모델

1 차 모델링에서는 LAST_GRADE 를 하나의 다중분류 목표변수로 설정하고, LightGBM 을 이용하여 16 개 최종등급을 직접 예측하였다. 전체 최종등급은 다음과 같이 구성하였다.

[등외, 3C, 3B, 3A, 2C, 2B, 2A, 1C, 1B, 1A, 1 + C, 1 + B, 1 + A, 1 + +C, 1 + +B, 1 + +A]

총 85 개 변수를 사용하였으며, 이 중 16 개가 범주형 변수였다. 클래스별 표본 수 차이를 보정하기 위해 inverse-frequency 방식의 balanced sample weight 를 적용하고, LAST_GRADE 를 기준으로 5-fold Stratified K-Fold 교차검증을 수행하였다.

주요 검증 결과는 다음과 같다.

- OOF Macro-F1: **0.230778**
- OOF Accuracy: **0.194568**
- OOF Balanced Accuracy: **0.261477**

이 모델은 전체 파이프라인과 제출 구조를 검증하는 기준모델 역할을 하였다. 그러나 육질등급과 육량등급이 결합된 16 개 클래스를 직접 예측하면서 최종등급의 계층적 구조를 반영하지 못했고, 다수 클래스와 희소 클래스 간 성능 차이가 크게 나타났다.

1.2 2 차 모델링: 독립형 2-stage LightGBM

2 차 모델링에서는 최종등급을 육질등급과 육량등급으로 분해하였다. 최종등급을 직접 예측하는 대신 다음 두 개의 분류문제를 별도로 학습하였다.

- **Stage Q:** 육질등급 6-class

[등외, 3, 2, 1, 1 + , 1 + +]

- **Stage Y:** 육량등급 3-class

[A, B, C]

Stage Q 는 전체 학습 데이터를 사용하였고, Stage Y 는 육량등급이 존재하지 않는 등외 표본을 제외하여 학습하였다. 두 단계 모두 LightGBM 을 사용하였다.

이 과정에서는 전체 변수군과 누수 위험이 있거나 일반화 가능성이 낮은 변수를 제외한 여러 feature set 을 비교하였다. 주요 feature set 은 다음과 같다.

- ALL: 약 97 개 변수
- SAFE_GEO: 95 개 변수
- SAFE_GEO_NO_FREQ: 89 개 변수

1-fold 검증에서는 SAFE_GEO 가 가장 높은 성능을 기록하였다.

설정	Validation Macro-F1
Direct LightGBM, soft weight ($\alpha = 0.5$)	0.240944
2-stage LightGBM, SAFE_GEO	0.245777
2-stage LightGBM, SAFE_GEO_NO_FREQ	0.244979

이후 SAFE_GEO 를 이용한 3-fold 교차검증 결과는 다음과 같다.

- OOF Macro-F1: **0.243607**
- OOF Accuracy: **0.225904**
- OOF Balanced Accuracy: **0.254925**

1 차 단일 LightGBM 의 Macro-F1 0.230778 에서 0.243607 로 향상되어, 최종등급을 육질과 육량으로 분리하는 접근이 효과적임을 확인하였다. 이후 모델링은 2-stage 구조를 중심으로 진행하였다.

다만 이 단계에서는 Stage Q 와 Stage Y 가 모두 LightGBM 으로 구성되었으며, 두 확률을 결합하는 방식도 후속 HPS 모델보다 단순하였다.

1.3 3 차 모델링: 단일 16-class XGBoost

3 차 모델링에서는 알고리즘 자체의 차이를 확인하기 위해 XGBoost 기반 단일 16-class 분류모델을 구축하였다. 기상·지역·농장 관련 파생변수를 확장하여 총 177 개 후보변수를 구성하였으며, target-prior 성격의 변수를 제외한 153 개 변수를 최종 학습에 사용하였다. 이 중 범주형 변수는 22 개였다. 먼저 약 30 만 건의 stratified sample 을 이용해 AutoGluon 기반 모델 screening 을 수행하였다.

모델	Validation Macro-F1
WeightedEnsemble_L2	0.212857
XGBoost	0.211121

LightGBM	0.204655
LightGBMXT	0.204560
NeuralNetTorch	0.199669
RandomForest	0.190277

단일 모델 중에서는 XGBoost 가 가장 높은 성능을 보였다. 이를 바탕으로 전체 데이터에 대해 XGBoost 3-fold 교차검증을 수행한 결과는 다음과 같다.

- OOF Macro-F1: **0.228036**
- OOF Accuracy: **0.233810**
- OOF Balanced Accuracy: **0.230036**

XGBoost 는 개별 알고리즘 screening 에서는 LightGBM 보다 높은 성능을 보였으나, 16 개 최종등급을 직접 예측한 전체 모델의 Macro-F1 은 2 차 2-stage LightGBM 의 0.243607 보다 낮았다.

따라서 3 차 실험을 통해 다음 두 가지를 확인하였다.

1. 복잡한 비선형 관계를 학습하는 Stage Q 후보로 XGBoost 를 활용할 가능성이 있음.
2. 알고리즘 변경만으로는 최종등급의 계층적 구조를 반영한 2-stage 모델을 대체하기 어려움.

1.4 4 차 모델링: 육질등급별 육량 specialist 구조

4 차 모델링은 이전 답변에서 설명한 단순 알고리즘 조합 비교가 아니라, 육질등급별로 육량모델을 분리한 조건부 계층 구조이다.

구조는 다음과 같다.

1. Stage 1 에서 육질등급 6 개를 예측
2. 등외를 제외한 각 육질등급별로 별도의 A/B/C 분류기를 학습
3. Stage 1 과 각 specialist 의 결과를 결합하여 16 개 최종등급 확률 생성

총 153 개 변수를 사용하였고, 저장된 노트북에서 실제 실행된 모델은 **Stage 1 LightGBM + Stage 2 LightGBM** 조합이다. XGBoost 나 CatBoost 조합은 실행 결과가 저장되어 있지 않으므로 실제 비교 결과로 볼 수 없다.

3-fold 교차검증 결과는 다음과 같다.

- Stage 1 육질등급 OOF Macro-F1: **0.484851**

- Stage 1 Accuracy: **0.425798**
- 최종 16-class OOF Macro-F1: **0.226906**
- 최종 Accuracy: **0.235905**
- 최종 Balanced Accuracy: **0.227504**

육질등급 자체는 일정 수준으로 예측하였으나, 각 육질그룹을 다시 A/B/C 로 분할하면서 specialist 별 학습 표본이 감소하였다. 특히 2C, 1C, 1+C 와 같은 희소 C 등급의 F1 이 매우 낮게 나타나 최종 Macro-F1 이 감소하였다.

따라서 육질등급별 specialist 를 단순히 분리하는 방식은 전체 육량 데이터를 함께 사용하는 2 차의 global Stage Y 보다 안정적이지 않은 것으로 판단하였다.

1.5 5 차 모델링: Hierarchical Probability Scoring 도입

5 차 모델링에서는 2-stage 구조를 유지하면서 다음 두 가지를 변경하였다.

- Stage Q: XGBoost
- Stage Y: LightGBM
- 최종 결합: class argmax 또는 단순 조합이 아닌 로그 확률 기반 scoring

사용한 feature set 은 FS1_DROP_ZERO 로, 총 140 개 변수 중 22 개가 범주형 변수였다.

각 최종등급 (k)의 점수는 다음과 같이 정의하였다.

$$s_k = \alpha \log P_Q(q_k | X) + \beta \log P_Y(y_k | X) + b_k$$

여기서

- $P_Q(q_k | X)$: 해당 최종등급의 육질등급 확률
- $P_Y(y_k | X)$: 해당 최종등급의 육량등급 확률
- α : 육질 확률의 반영 강도
- β : 육량 확률의 반영 강도
- b_k : 최종등급별 bias

등외는 육량등급이 존재하지 않으므로 다음과 같이 계산하였다.

$$s_{\text{등외}} = \alpha \log P_Q(\text{등외} | X) + b_{\text{등외}}$$

최종 예측등급은 다음 기준으로 결정하였다.

$$\hat{y} = \underset{k}{\operatorname{argmax}} s_k$$

이 방식의 핵심은 Stage Q와 Stage Y의 최빈 클래스를 먼저 확정하지 않고, 각 단계에서 산출한 **전체 확률분포를 최종 16-class 점수에 반영**한다는 점이다. 따라서 1 순위 확률이 유사한 경계 표본에서도 불확실성을 보존할 수 있다.

1.6 6 차 모델링: Conditional Hierarchical Model 및 direct-model ensemble

2.6.1 육질 조건부 육량모델

6 차 모델링에서는 Stage Q를 XGBoost로 학습한 뒤, 하나의 global Stage Y 대신 육질등급별 LightGBM specialist를 구축하였다.

$$P(Y|Q=q,X), q \in \{3,2,1,1+,1++\}$$

총 140 개 변수를 사용하였으며, 기본 scoring 구조는 5 차의 로그 확률 결합 방식을 유지하였다.

Bias를 적용하기 전 $\alpha \cdot \beta$ 탐색에서 가장 높은 성능은 다음 설정에서 나타났다.

$$\alpha = 1.5, \beta = 0.5$$

이때 성능은 다음과 같다.

- OOF Macro-F1: **0.243319**
- OOF Accuracy: **0.224410**
- OOF Balanced Accuracy: **0.257433**

이후 class-wise bias를 적용한 결과는 다음과 같다.

- OOF Macro-F1: **0.250354**
- OOF Accuracy: **0.219788**
- OOF Balanced Accuracy: **0.258867**

Bias 적용으로 Macro-F1 은 향상되었으나, 노트북 내부에서 비교한 이전 3-fold base 모델의 OOF Macro-F1 0.264897 보다 0.014543 낮았다. 또한 육량 A/B 구분은 일부 개선되었지만, 육질 1 과 1+ 경계의 정확도가 감소하였다.

따라서 육질별로 육량모델을 분리한 조건부 구조는 global Stage Y 보다 안정적인 성능 향상을 제공하지 못하였다.

2.6.2 Direct 16-class 모델과의 ensemble

6 차 노트북에서는 조건부 모델 외에 LightGBM, XGBoost, CatBoost 기반 direct 16-class 모델도 추가로 실험하였다. 전체 3-fold 로 실행된 direct LightGBM 의 결과는 다음과 같다.

- Direct LightGBM OOF Macro-F1: **0.239096**

기존 hierarchical model 과 direct model 의 확률 또는 margin 을 결합한 ensemble 에서는 OOF Macro-F1 이 약 **0.265521** 까지 상승하였다. 그러나 기존 base 대비 향상 폭이 약 0.0006 수준으로 작았고, 외부 Public 성능 개선이 확인된 결과는 저장되어 있지 않았다.

이에 따라 계산량과 구현 복잡도를 증가시키는 ensemble 은 최종 모델에서 제외하였다.

1.7 7 차 모델링: Global-Specialist 혼합 3-stage 모델

7 차 모델링에서는 global Stage Y 와 육질별 specialist Stage Y 를 동시에 학습하고, 두 확률을 혼합하는 3-stage 구조를 적용하였다.

구조는 다음과 같다.

1. Stage Q: XGBoost 육질등급 예측
2. Stage Y-global: LightGBM 기반 전체 비등외 표본의 A/B/C 예측
3. Stage Y-specialist: 육질등급별 LightGBM A/B/C 예측
4. global 확률과 specialist 확률을 가중결합

혼합 육량확률은 다음과 같이 정의하였다.

$$P_{Y,mix} = \lambda_{global} P_{Y,global} + (1 - \lambda_{global}) P_{Y,specialist}$$

총 161 개 변수를 사용하였으며, 22 개가 범주형 변수였다.

탐색 결과 최적 설정은 다음과 같았다.

$$\lambda_{global} = 1.0, \alpha = 1.29, \beta = 0.69$$

그러나 $\lambda_{global} = 1.0$ 이면 $P_{Y,mix} = P_{Y,specialist}$ 이므로 specialist 예측은 최종 결과에 전혀 반영되지 않는다. 즉, 탐색 결과 자체가 육질 조건부 specialist 보다 global Stage Y가 더 적합하다는 것을 보여준다.

저장된 OOF 결과는 다음과 같다.

- OOF Macro-F1: **0.230913**
- OOF Accuracy: **0.237456**
- OOF Balanced Accuracy: **0.231375**

테스트 예측에서는 육량등급 B의 비율이 약 74.99%, C의 비율이 약 3.42%로 나타나 예측 분포가 B 등급에 과도하게 집중되었다. 기존 최적 제출 파일과의 최종등급 일치율도 약 58.94%에 그쳤다.

프로젝트 제출 이력상 해당 3-stage 결과의 Public Macro-F1은 약 **0.215**였으며, 최종 모델보다 낮았다. 따라서 specialist를 추가한 3-stage 구조는 제외하고 global Stage Y를 사용하는 2-stage 구조로 복귀하였다.

1.8 최종 모델 선정

전체 실험 결과를 종합하여 다음 구조를 최종 모델로 선정하였다.

- **Stage Q:** XGBoost 기반 육질등급 6-class 분류
- **Stage Y:** LightGBM 기반 global 육량등급 3-class 분류
- **결합 방식:** Hierarchical Probability Scoring
- **검증 방식:** 3-fold Stratified K-Fold
- **불균형 처리:** soft class weight
- **후처리:** 고정 class-wise bias 적용

최종 선정은 단순히 가장 복잡한 구조를 선택한 것이 아니라, 다음 실험 결과에 근거하였다.

- Direct 16-class 보다 육질·육량 분해 구조가 높은 Macro-F1을 기록함.
- 육질분류에서는 XGBoost가 단일 모델 screening에서 LightGBM보다 우수한 결과를 보임.
- global Stage Y가 품질등급별 specialist보다 안정적이었음.
- 7차의 최적 혼합계수가 ($\lambda_{global} = 1.0$)으로 결정되어 specialist의 추가 효과가 없음을 확인함.
- 로그 확률 결합과 class-wise bias를 적용한 최종 재현 모델이 **Public Macro-F1 0.244**를 기록함.

2. 최종 모델 구현

2.1 최종 입력변수

최종 feature set 은 B_LINEAGE_FREQ_ONLY 이며 다음과 같이 구성되었다.

- 전체 변수: **161 개**
- 범주형 변수: **22 개**
- 수치형 변수: **139 개**

범주형 변수는 다음과 같다.

<i>JUDGE_SEX</i>	<i>is_castrated</i>
<i>JUDGE_YEAR</i>	<i>is_female</i>
<i>abatt_month</i>	<i>is_male</i>
<i>age_band</i>	<i>is_summer</i>
<i>area_record_missing</i>	<i>is_winter</i>
<i>climate_cluster</i>	<i>scale_band</i>
<i>death_flag_180d_before_abatt</i>	<i>scale_increased</i>
<i>death_flag_365d_before_abatt</i>	<i>season_code</i>
<i>death_flag_before_abatt</i>	<i>sex_code</i>
<i>density_band</i>	<i>sido</i>
<i>weight_band</i>	<i>sigungu</i>

수치형 결측치는 학습 데이터의 중앙값으로 대체하였다. 범주형 변수는 train 과 test 에서 동일한 category coding 을 적용하여 두 데이터 간 범주 코드의 불일치를 방지하였다.

최종 feature set 은 개체, 도축 시점, 농장, 지역, 기상, 폐사, 혈통 빈도 관련 변수를 포함하되, 과도하게 고차원인 혈통 ID 자체보다 빈도 및 보유 여부 중심으로 구성하였다.

2.2 교차검증

전체 16 개 LAST_GRADE 의 비율을 각 fold 에서 유지하기 위해 다음 설정을 사용하였다.

- Stratified K-Fold
- Fold 수: 3
- Stratification 기준: LAST_GRADE 16-class
- Random state: 42

각 fold 에서 Stage Q와 Stage Y를 별도로 학습하였다.

- Stage Q: 해당 fold 의 전체 학습 표본 사용
- Stage Y: 해당 fold 의 학습 표본 중 등외 제외
- 검증 fold: Stage Q와 Stage Y 확률을 모두 OOF 배열에 저장
- Test: 세 fold 의 예측확률 평균 사용

2.3 Stage Q: XGBoost 육질등급 모델

Stage Q의 목표변수는 다음 6개 육질등급이다.

{~~등외~~, 3, 2, 1, 1+, 1++}

주요 설정은 다음과 같다.

하이퍼파라미터	설정값
Objective	multi:softprob
n_estimators	1,400
max_depth	8
learning_rate	0.035
subsample	0.85
colsample_bytree	0.85
min_child_weight	20
reg_lambda	3
tree_method	hist
device	cuda

각 fold 의 Stage Q 성능은 다음과 같다.

Fold	Macro-F1	Accuracy
1	0.476534	0.417777
2	0.475412	0.417753
3	0.477795	0.418592

fold 간 성능 편차가 작아 육질등급 모델의 학습 결과가 비교적 안정적으로 나타났다.

2.4 Stage Y: LightGBM 육량등급 모델

Stage Y는 등위를 제외한 표본을 이용하여 다음 세 육량등급을 예측하였다.
 $\{C, B, A\}$

주요 설정은 다음과 같다.

하이퍼파라미터	설정값
Objective	multiclass
num_boost_round	2,500
learning_rate	0.045
num_leaves	63
min_data_in_leaf	100
feature_fraction	0.85
bagging_fraction	0.85
lambda_l1	0.1
lambda_l2	1.0

각 fold의 Stage Y 성능은 다음과 같다.

Fold	Macro-F1	Accuracy
1	0.499661	0.533595
2	0.498784	0.532852
3	0.498997	0.532489

Stage Y 역시 fold 별 성능 차이가 매우 작았으며, global 육량모델의 안정성을 확인할 수 있었다.

2.5 Soft class weight

육질 및 육량등급의 표본 불균형을 완화하기 위해 다음과 같은 soft class weight를 적용하였다.

$$w_c = \left(\frac{N}{Kn_c}\right)^{0.5}$$

- N: 해당 Stage의 전체 학습 표본 수
- K: 클래스 수
- n_c : 클래스 c의 표본 수

일반적인 inverse-frequency weight 를 그대로 사용하지 않고 제곱근을 적용하였다. 이를 통해 희소 클래스에 더 높은 중요도를 부여하면서도, 극소수 클래스의 가중치가 지나치게 커져 전체 학습을 불안정하게 만드는 문제를 완화하였다.

2.6 Hierarchical Probability Scoring

최종 모델은 다음 가중치를 사용하였다.

$$\alpha = 1.15, \beta = 0.85$$

따라서 비등외 최종등급의 점수는 다음과 같다.

$$s_k = 1.15 \log P_Q(q_k | X) + 0.85 \log P_Y(y_k | X) + b_k$$

육질 확률의 가중치를 육량 확률보다 높게 설정하였다. 이는 최종등급의 상위 구조를 형성하는 육질등급의 구분력을 상대적으로 크게 반영하기 위한 것이다.

2.7 Class-wise bias 적용

기본 HPS 결과에서 일부 클래스는 실제 분포보다 과대 예측되고, 일부 희소 클래스는 과소 예측되는 현상이 나타났다. 이를 보정하기 위해 최종 재현 코드에서는 기존 Public 최적 제출에서 사용한 고정 bias 를 적용하였다.

Bias strength 는 0.75 이며, 실제 적용된 값은 다음과 같다.

등급	적용 bias
등외	-1.5000
3C	-0.2250
3B	-0.4125
3A	-0.3000
2C	+0.2250
2B	0.0000
2A	-0.0750
1C	+0.2250

1B	+0.0750
1A	+0.0750
1+C	+0.1500
1+B	+0.0750
1+A	+0.0750
1++C	-0.1500
1++B	-0.1500
1++A	-0.0750

주로 과대 예측되는 등외, 3B, 3A 등에 음의 bias 를 부여하고, 상대적으로 과소 예측되는 일부 C 등급 및 중간 등급에는 양의 bias 를 부여하였다.

다만 이 bias 는 학습모델 자체의 파라미터가 아니라 **최종 확률 점수에 적용되는 후처리 값**이다.

3. 성능 요약

3.1 모델별 OOF 성능

차수	모델 구조	OOF Macro-F1	Accuracy	Balanced Accuracy
1 차	Direct 16-class LightGBM	0.230778	0.194568	0.261477
2 차	Global 2-stage LightGBM	0.243607	0.225904	0.254925
3 차	Direct 16-class XGBoost	0.228036	0.233810	0.230036
4 차	LightGBM Quality + 품질별 Yield specialist	0.226906	0.235905	0.227504
6 차	XGBoost Quality + 조건부 Yield, bias 적용	0.250354	0.219788	0.258867
6 차	Direct 16-class LightGBM	0.239096	-	-
7 차	Global-Specialist 혼합 3-stage	0.230913	0.237456	0.231375
최종	XGBoost Q + LightGBM Y, 기본 HPS	0.243751	0.224788	0.264329
최종	기본 HPS + 고정 class bias	0.258426	0.222524	0.260872

표의 OOF 성능은 각 노트북에서 사용한 feature set 과 후처리 방식이 일부 다르므로 완전히 동일한 조건의 단일 비교실험으로 해석해서는 안 된다. 특히 6 차와 최종 모델의 bias 적용 성능은 OOF 예측을 바탕으로 후처리 계수가 결정된 결과이므로, 기본 모델 성능보다 낙관적으로 측정될 가능성이 있다.

3.2 최종 성능

최종 모델의 확정 결과는 다음과 같이 구분된다.

평가 구분	Macro-F1
기본 HPS OOF	0.243751
고정 class bias 적용 OOF	0.258426
Public Leaderboard	0.244

보고서의 대표 외부 성능으로는 **Public Macro-F1 0.244** 를 기록하였다.

3.3 모델 개선 흐름

모델 개발 과정은 다음과 같이 요약할 수 있다.

Direct 16-Class ▷ 독립형 2-stage ▷ 품질별 specialist ▷ 확률 기반 HPS
▷ 조건부 혼합 3-Stage ▷ Global 2-STAGE HPS 복귀

주요 성능 변화는 다음과 같다.

1. Direct LightGBM 에서 2-stage LightGBM 으로 변경하면서 Macro-F1 이 0.230778 → 0.243607 로 향상되었다.
 2. Direct XGBoost 와 품질별 specialist 구조는 각각 0.228036, 0.226906 으로 2-stage global 모델보다 낮았다.
 3. 조건부 specialist 와 3-stage 구조를 추가하였으나, 일관된 외부 성능 개선이 나타나지 않았다.
 4. 7 차 혼합모델에서 최적 λ_{global} 이 1.0 으로 선택되면서 global Stage Y 가 specialist 보다 적합함을 확인하였다.
 5. 최종적으로 XGBoost Stage Q 와 LightGBM global Stage Y 를 HPS 로 결합하고 class-wise bias 를 적용하여 Public Macro-F1 0.244 를 기록하였다.
-

4. 최종 모델 선정 근거

최종 모델은 XGBoost 기반 육질등급 분류와 LightGBM 기반 global 육량등급 분류를 결합한 2-stage Hierarchical Probability Scoring 모델로 선정하였다.

첫째, 육질과 육량으로 문제를 분해한 2-stage 모델은 단일 16-class LightGBM 과 XGBoost 보다 높은 Macro-F1 을 기록하였다.

둘째, XGBoost 는 AutoGluon screening 에서 단일 boosting 모델 중 가장 높은 성능을 보여, 복잡한 개체·농장·혈통·기상 변수 간 관계를 학습하는 Stage Q 에 적용하였다.

셋째, LightGBM global Stage Y 는 약 240 만 건의 대규모 데이터와 범주형 변수를 효율적으로 처리하면서 fold 별로 안정적인 육량 예측 성능을 보였다.

넷째, 육질별 specialist 를 추가한 4 차·6 차·7 차 모델은 표본 분할로 인해 희소 육량등급의 학습이 불안정해졌고, 최종 성능 향상으로 이어지지 않았다.

다섯째, 7 차 모델에서 최적 global 혼합계수가 1.0 으로 결정되었다. 이는 specialist 를 추가한 복잡한 구조보다 하나의 global 육량모델을 사용하는 구조가 더 적합하다는 직접적인 실험 결과이다.

여섯째, HPS 는 각 Stage 의 argmax 결과만 이용하지 않고 전체 확률분포를 보존하므로, 인접 등급 간 불확실성을 최종 16-class 예측에 반영할 수 있다.

마지막으로 3-fold 구조는 대규모 데이터에서 계산비용을 관리하면서도 fold 별 Stage Q 와 Stage Y 성능 편차가 작아 안정적인 재현이 가능하였다.

5. 결론

본 모델링에서는 단일 16-class LightGBM 을 기준모델로 시작하여, 독립형 2-stage, direct XGBoost, 육질별 specialist, Conditional Hierarchical Model, global-specialist 혼합 3-stage 를 순차적으로 검토하였다.

실험 결과, 최종등급을 육질과 육량으로 분리하는 접근은 단일 다중분류보다 효과적이었으나, 육질등급별로 육량 specialist 를 추가하는 방식은 학습 표본 감소와 희소 클래스 성능 저하로 인해 안정적인 개선을 제공하지 못하였다. 특히 7 차 모델에서는 최적 혼합계수가 global Stage Y 만 사용하도록 결정되어, specialist 구조의 필요성이 낮음을 확인하였다.

이에 따라 최종 모델은 161 개 변수를 이용하여 육질등급을 XGBoost 로, 육량등급을 LightGBM 으로 학습한 뒤 두 예측확률을 Hierarchical Probability Scoring 으로 결합하는 구조로 구성하였다. Soft class weight 와 고정 class-wise bias 를 적용한 결과, 내부 OOF Macro-F1 은 0.258426, 최종 Public Macro-F1 은 **0.244** 를 기록하였다.

따라서 최종 모델은 성능뿐 아니라 계산 효율성, 재현성, 모델 구조의 명확성까지 고려할 때, 조건부 specialist 를 포함한 복잡한 3-stage 모델보다 **global 2-stage Hierarchical Probability Scoring** 이 가장 적절한 것으로 판단된다.